joint8-20k / step10000 三专家采样与推理机评测

更新：2026-10-21。本机 step10000 采样评测与 4090 同输入延时对照均已完成；结论只适用于本报告列出的离线推理，不代表机械臂闭环成功率。

推荐

优先真机验证 Video=4、Force=4、Action=16。 本机 RGB→动作与力输出 P50 **762.7 ms**、P95 **779.0 ms**，对同组同次基线的配对速度比为 **2.62×**。97 个事件窗口上的关节误差较基线降低 2.4%，力误差降低 9.2%；动作速度差分误差增加 4.1%，二阶差分误差增加 4.8%。这是响应速度与离线轨迹误差的折中选择，不是已验证的成功率最优策略。

8/8/16 作为优先保留轨迹质量的对照。 RGB 完整处理 P50 1090.1 ms，事件窗口速度差分误差降低 2.2%，二阶差分误差降低 2.2%，其他汇总误差也接近或低于基线。它在本机已接近或超过 32 点动作块的 1.067 s 覆盖时长，不适合据此承诺连续异步控制。

4/8/16 比 4/4/16 多约 29 ms，事件窗口关节、速度、夹爪误差稍小，而力误差稍大，可作为真机第三候选。4/4/8 的完整处理约 666 ms；4/4/4 最快约 627 ms，但事件窗口速度差分误差增加 23.3%、二阶差分误差增加 26.2%，因此不凭更小的位置 MAE 选它作唯一默认。

阅读导航

权重、数据与数值协议 2
本机 GB10 时延实测 3
与录制 GT 的离线误差 4
视频质量与离线演示 7
为什么优先减少 Video 步数 7
异步部署的实际约束 7
GB10 与 RTX 4090 实测对照 8
复现 9

权重、数据与数值协议

- 训练任务 `job-0091e5fd-71df-4582-b5b0-fd272204bd9b`，joint8-20k SSD 续训任务，检查点 `step_010000.pt`，文件头 step=10000。
- SHA256 `2e8409d495d11961614b72d81b25bec7cc71bc2e194acb15ea220a72edace1d8`；模型约 28.24 亿参数；评测不改训练参数。
- V/F/A 依次为 **视频/力/动作**。基线三个专家各 16 步；4、8、16 的笛卡尔积 27 配置 × 50 midpoint 窗口 × 3 种子 = **4,050** 次预测。
- 额外按 GT 夹爪范围、力变化选取 **97** 个窗口，9 配置 × 3 种子 = **2,619** 次预测。共 **6,669** 次质量预测；另有 450 次视频解码质量评分与 330 组核心/RGB 配对时延样本。
- 所有 50 个 episode 都参与过训练。97 个窗口选自同一批 episode；不是训练留出集、成功抓取标注或独立的 97 个任务。配对 bootstrap 的单位为 episode，不能推断泛化能力。
- batch=1、BF16、224×448 双相机拼接；动作和力各 32 点、30 Hz。视频 9 帧含当前帧，未来 8 帧按 7.5 Hz 评分。种子 action/force/video = 42+s/43+s/44+s，s=0、1、2。
- 每个专家在自身 Euler 区间起点计算方向、区间终点更新状态。较少步专家在区间内保持状态和时钟，其逐层 K/V 可精确复用。Video 更新会触发 Action 所需的 Force 特征重算；名义 Force 积分步数不总等于 Force 前向次数。完整计数保存在 `report.json` 的 `runner_stats`。
- 这是多速率联合积分与固定状态特征复用；没有跨变化状态近似外推动作方向。所有组合通过完整模型独立参考实现校验，阈值为归一化 max≤0.05、mean≤0.01。该阈值仅用于实现一致性，不是物理质量阈值。

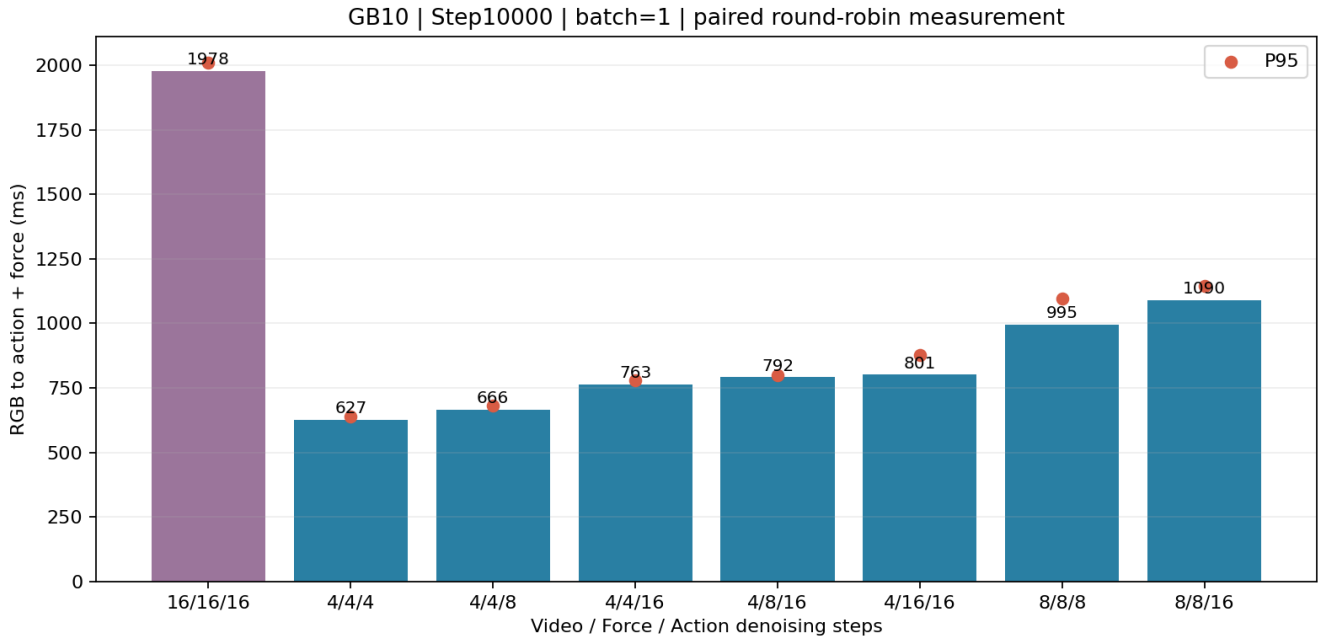
本机 GB10 时延实测

V/F/A	样本 n	核心 P50/P95 ms	RGB→动作/力 P50/P95 ms	RGB 配对提速
16/16/16	120	1897/1929	1978/2011	1.00×
4/4/4	30	540/554	627/638	3.18×
4/4/8	30	583/592	666/680	2.99×
4/4/16	**30**	**680/692**	**763/779**	**2.62×**
4/8/16	30	706/718	792/798	2.52×
4/16/16	30	723/812	801/878	2.35×
8/8/8	30	919/1029	995/1096	1.86×
8/8/16	30	1016/1070	1090/1146	1.70×

核心时间包含前缀预填充、噪声、图输入复制与联合采样。RGB 路径从已解码双相机 RGB 开始，包含 resize、CPU→GPU、VAE、联合核心、GPU→CPU、动作/力反归一化。**不含相机采集、视频压缩解压、网络、机器人执行或生成视频解码。** VAE/图像前处理约 75–81 ms。

每次配对交替执行基线和最多两个候选，顺序按 repetition 轮转，30 次/候选；基线跨四组共 120 次。设备频率在测试中有变化，所以速度比采用同组同次的比值中位数，不直接将全局基线中位数除以每个候选。P95 为本次样本分位数，不是最大时延保证。

Torch 2.9.1+cu130 / ARM64 / GB10。已有编译缓存下的首次编译/捕获/预热约 1.75–7.57 s，单列在 `latency.json` 的 `setup_ms`，不是空缓存冷启动时间；不计入稳态。测量时同时保留多个候选图，PyTorch peak allocated 7.85–8.35 GiB、reserved 9.94–11.05 GiB，不代表单一部署实例最低显存。GB10 统一内存的 nvidia-smi memory=N/A 不能作为未用 GPU 的依据。



GB10 时延

与录制 GT 的离线误差

50 个 midpoint 窗口：

V/F/A	关节 MAE °	夹爪 MAE	速度差分 MAE °/s	加速度差分 MAE °/s²	力 MAE N	力矩 MAE Nm
16/16/16	0.1448	0.00284	1.314	63.53	0.0779	0.00492
4/4/4	0.1220	0.00278	1.675	83.37	0.0722	0.00474
4/4/8	0.1277	0.00232	1.450	71.77	0.0722	0.00474
4/4/16	**0.1392**	**0.00274**	**1.379**	**67.11**	**0.0722**	**0.00474**
4/8/16	0.1363	0.00274	1.354	65.85	0.0731	0.00477
4/16/16	0.1345	0.00269	1.340	64.96	0.0795	0.00496
8/8/8	0.1291	0.00257	1.368	67.03	0.0727	0.00473
8/8/16	0.1386	0.00277	1.241	59.89	0.0727	0.00473

97 个夹爪/力变化窗口：

V/F/A	关节 MAE °	夹爪 MAE	速度差分 MAE °/s	加速度差分 MAE °/s²	力 MAE N	力矩 MAE Nm
16/16/16	0.1446	0.01289	1.415	67.79	0.0800	0.00556
4/4/4	0.1257	0.01240	1.745	85.61	0.0726	0.00529
4/4/8	0.1300	0.01235	1.555	75.79	0.0726	0.00529
4/4/16	**0.1411**	**0.01299**	**1.473**	**71.06**	**0.0726**	**0.00529**
4/8/16	0.1390	0.01284	1.464	70.61	0.0750	0.00532
4/16/16	0.1380	0.01295	1.438	69.33	0.0812	0.00555
8/8/8	0.1331	0.01252	1.535	74.79	0.0743	0.00534
8/8/16	0.1405	0.01284	1.384	66.31	0.0743	0.00534

所有数值为按有效目标数加权的 MAE；夹爪为归一到 [0,1] 的开合度。速度和加速度指标来自预测与 GT 的差分误差；它们并不直接证明机械稳定性。位置均值误差更小，不代表动作抖动更小。

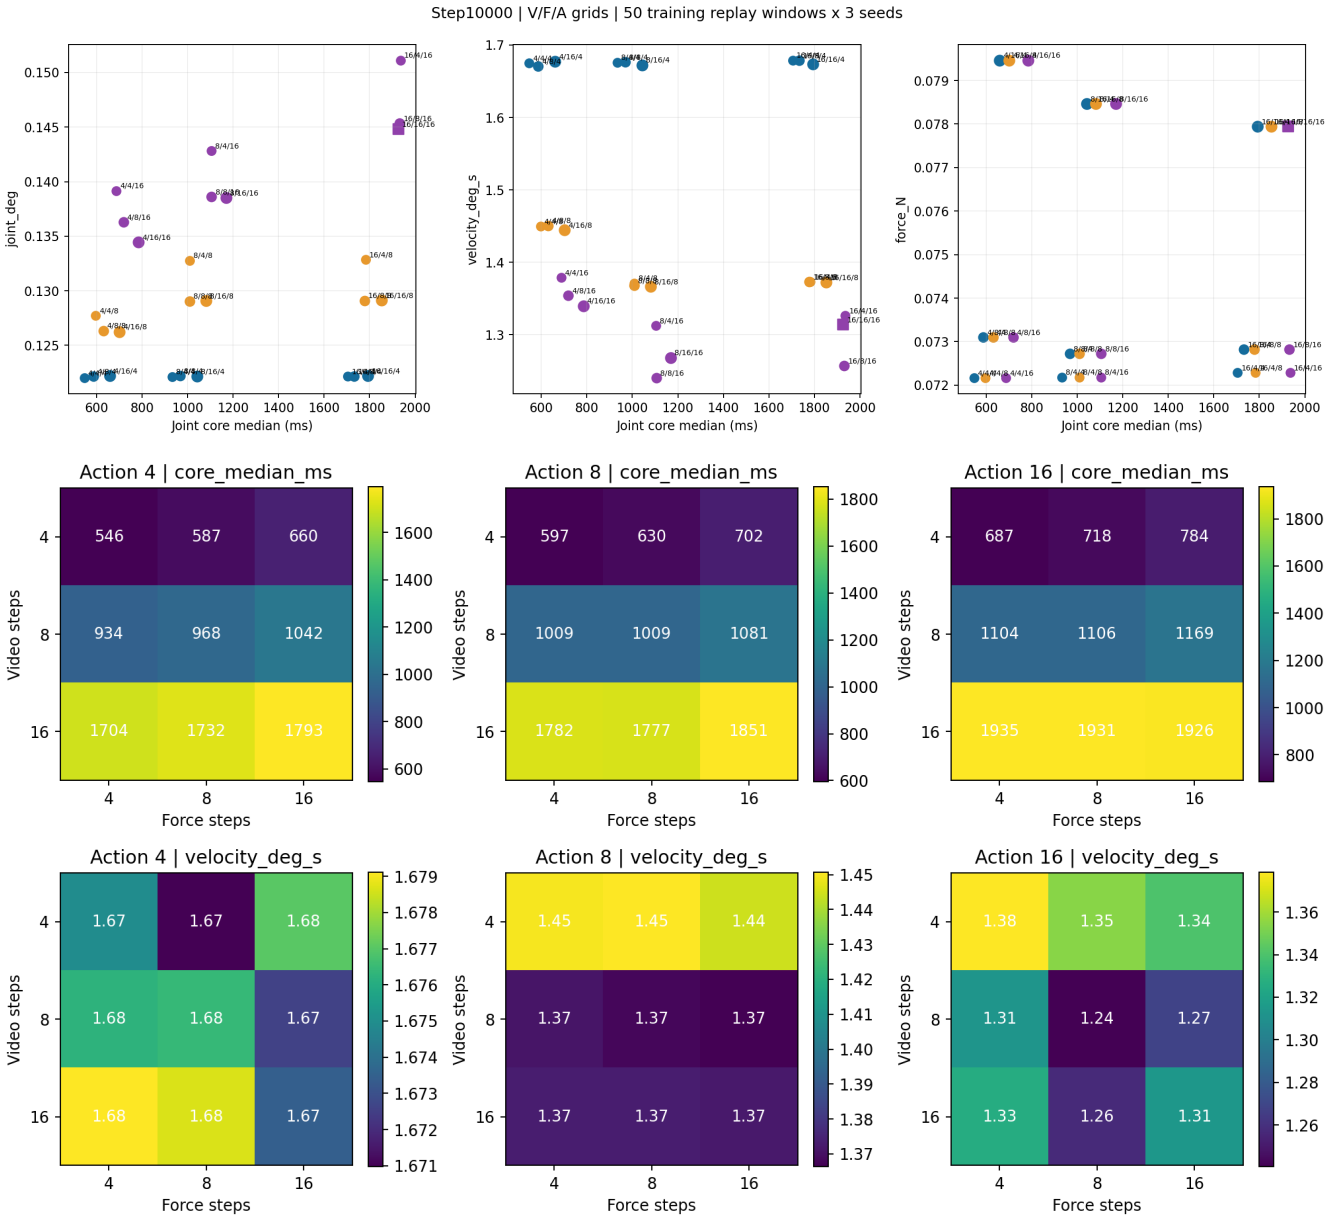
事件窗口按 episode 配对 bootstrap 5,000 次，差值为候选减基线，负数更小：

V/F/A	指标	差值均值	95% 区间	改善 episode	变差 episode
4/4/16	**joint_deg**	**-0.00358**	**[-0.00556, -0.00155]**	**34**	**15**
4/4/16	**velocity_deg_s**	**+0.05682**	**[+0.03453, +0.07827]**	**12**	**37**
4/4/16	**force_N**	**-0.00742**	**[-0.00965, -0.00530]**	**42**	**7**
4/8/16	joint_deg	-0.00560	[-0.00784, -0.00335]	33	16
4/8/16	velocity_deg_s	+0.04866	[+0.03080, +0.06548]	9	40
4/8/16	force_N	-0.00508	[-0.00703, -0.00343]	42	7
8/8/16	joint_deg	-0.00410	[-0.00555, -0.00263]	40	9
8/8/16	velocity_deg_s	-0.03253	[-0.04613, -0.01839]	36	13
8/8/16	force_N	-0.00568	[-0.00662, -0.00476]	46	3

夹爪变化时刻：每种配置共有 126 个窗口×种子事件，均漏检 1 个；检测到的时刻绝对误差 P50=33.3 ms、P95=66.7 ms、最大=166.7 ms。阈值按每个窗口 GT 最大最小开合度中点设定，并要求 GT 变化≥0.1；这是离线阈值穿越误差，不是成功率。各配置分位数相同，也不代表逐次预测完全相同。

完整 27 组 CSV：网格汇总。事件 CSV：变化窗口汇总。`analysis.json` 含逐种子、最差窗口、首动作跳变误差和配对区间；`records.jsonl` 与 NPZ 保留逐次预测。

采样配置的速度与质量分布



视频质量与离线演示

Video 步数	全局相机 PSNR dB / SSIM	腕部相机 PSNR dB / SSIM
4	36.798 / 0.97627	33.580 / 0.95066
8	36.789 / 0.97629	33.507 / 0.95037
16	36.768 / 0.97619	33.456 / 0.94986

450 个窗口/种子/视频步数组合，每次只统计未来 8 帧、相机分别评分；含 VAE 重建误差。4 步与 8/16 步差异很小。该指标主要受背景像素影响，不能代替抓杯动作正确性判断。

演示固定 seed0，显示录制双相机与基线、4/4/16、8/8/16 的预测视频；旁边有完整 7 关节、夹爪、力/力矩 GT 曲线。视频为慢放并循环，标签时间为实际预测相对时间。

- 夹爪变化最大：ep8/frame152 视频 · 动作 · 力
- 力变化最大：ep14/frame517 视频 · 动作 · 力
- 候选较差动作窗口：sample7573 视频 · 动作 · 力

选片规则保存在 `provenance/demo-selection.json`，包括 GT 最大变化和候选最差片段，没有只展示模型最好的样本。**演示全部为离线观测回放；预测视频不等于动作已经执行，更不等于闭环抓取成功。**

为什么优先减少 Video 步数

27 组时延对实际前向次数的描述性拟合：Video 每次约 95.5 ms、Force 每次约 8.5 ms、Action 每次约 11.0 ms，固定项约 92.9 ms；R^2=0.99994。它是各配置中位数的回归，不是逐 kernel profiler，也不保证迁移到 4090 后系数相同。它说明本机主要收益来自减少昂贵的视频计算，保留动作 16 步的增量成本相对有限。

低步数位置误差更小并不违反数值原理：网络是近似向量场，更多 Euler 步只改善对该场的积分精度，不能保证更接近 GT。训练数据回放、噪声、有限数据和所选指标都可能造成低步数更优。当前证据同时显示部分差分指标随动作减步变差，因此不把“误差小”表述为“成功率高”。

异步部署的实际约束

32 个 30Hz 动作点约覆盖 1.067 s。4/4/16 的本机处理 P95≈0.779 s，若完整执行 32 点，留给传感器、传输、排队、接续的理论余量约 0.288 s；因此值得实现并测试异步。但若每次仅执行前 8 点（267 ms），当前时延仍不足以持续更新。8/8/16 的 P95≈1.146 s 已超过该动作块覆盖时间。

4090 上 4/4/16 RGB→输出 P95 为 0.351 s；若执行完整 32 点，理论余量约 0.716 s。通过本次启智代理的 JPEG 探测加本机编码，粗略 P95 约 0.383 s，仍高于 8 点动作块的 0.267 s；代理探测不含生产服务排队和远端解码，所以不能据此承诺闭环异步周期。

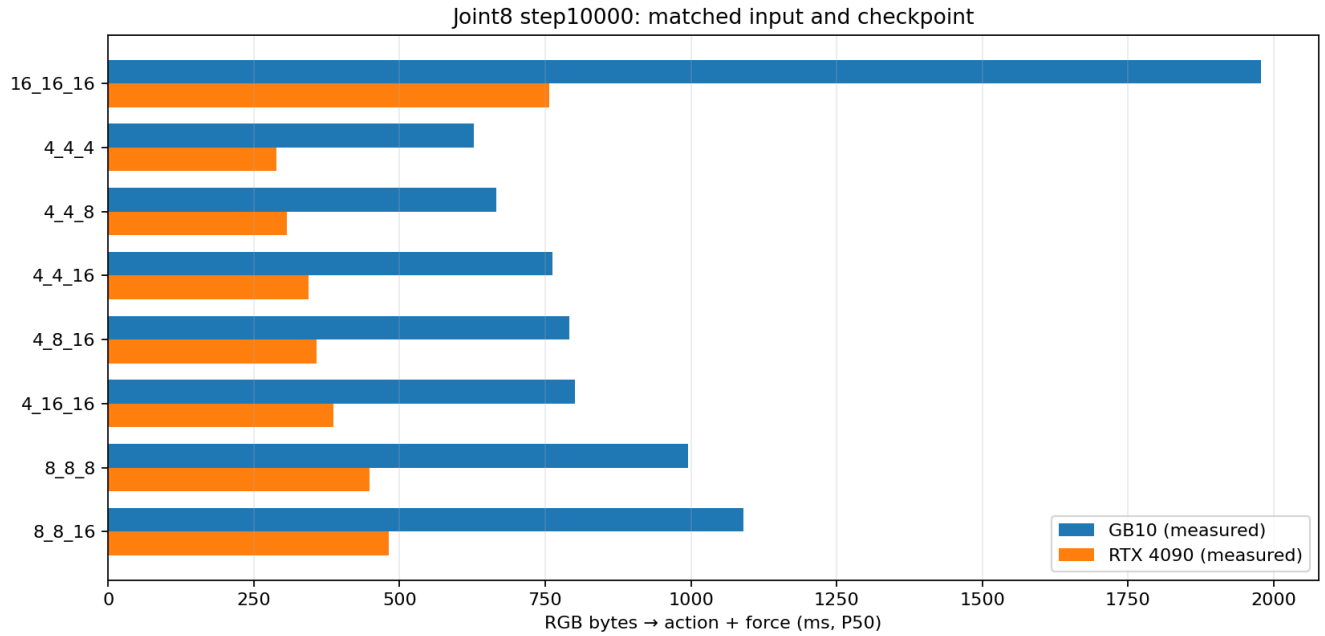
异步仍需基于新观测生成后续块，按观测时间戳剔除已过时前缀、预填当前执行块、平滑接续；相邻请求之间只使用最新观测。同步/异步的真机对比应固定检查点、采样设置、任务初始条件和执行动作数，单独记录成功率、接触力峰值、观测龄期和停顿占比。

GB10 与 RTX 4090 实测对照

4090 实例已完成实测。表中每个候选为 30 次同输入重复，16/16/16 基线在四个交替组共 120 次；同组每次轮换执行顺序。核心延时和 RGB→输出延时分别给出 P50/P95。两个设备使用完全相同的权重 SHA、输入 SHA、评测源码 SHA、batch=1、BF16 和采样配置；4090 为 Torch 2.9.1+cu128 / CUDA 12.8 / x86_64，GB10 为 Torch 2.9.1+cu130 / CUDA 13 / ARM64。

V/F/A	核心 GB10 P50 / P95	核心 4090 P50 / P95	RGB GB10 P50 / P95	RGB 4090 P50 / P95	GB10/4090 P50 比	相对 16 步提速 GB10 / 4090
16/16/16	1897/1929 ms	698/709 ms	1978/2011 ms	756/765 ms	2.62×	1.00× / 1.00×
4/4/4	540/554 ms	232/240 ms	627/638 ms	289/294 ms	2.17×	3.18× / 2.60×
4/4/8	583/592 ms	249/252 ms	666/680 ms	307/309 ms	2.17×	2.99× / 2.45×
4/4/16	**680/692 ms**	**286/309 ms**	**763/779 ms**	**344/351 ms**	**2.21×**	**2.62× / 2.20×**
4/8/16	706/718 ms	300/302 ms	792/798 ms	358/363 ms	2.21×	2.52× / 2.12×
4/16/16	723/812 ms	329/344 ms	801/878 ms	386/395 ms	2.07×	2.35× / 1.96×
8/8/8	919/1029 ms	389/398 ms	995/1096 ms	448/465 ms	2.22×	1.86× / 1.69×
8/8/16	1016/1070 ms	424/430 ms	1090/1146 ms	482/487 ms	2.26×	1.70× / 1.57×

RGB 指 RGB→动作/力输出。延时单位：ms；粗体着色行为推荐候选。



GB10 与 RTX 4090 延时对比

4090 对 16/16/16 RGB→输出为 **P50 756 ms / P95 765 ms**，GB10 为 **1978/2011 ms**，中位数约快 **2.62×**。推荐候选 4/4/16 在 4090 为 **344/351 ms**，GB10 为 **763/779 ms**；同一配置的跨设备中位数约快 **2.21×**。

4/4/4 在 4090 最快，RGB→输出 P50/P95=289/294 ms；但离线事件窗口显示动作速度差分误差增加约 23%，所以速度数据不改变 4/4/16 作为首个真机候选的判断。4090 将相同动作/力专家设置的 16/16/16 计算压到约 0.76 s，4/4/16 约 0.34 s；异步控制仍应结合实际网络、摄像头周期和动作块衔接一起测。 PyTorch 在 4090 的峰值 allocated/reserved 为 **8.35/11.05 GiB**，测试时 `nvidia-smi` 曾观测到约 12.7 GB 板载显存占用；GB10 分别为 **8.35/11.05 GiB**，其统一内存不能用 `nvidia-smi` memory 字段直接比较。

到服务器的传输开销实测

为了估计数据流上云的成本，本机通过当前启智 Jupyter HTTPS 代理向运行中的 4090 实例发 50 次轮换探测，每次服务器返回固定 16 KiB 确认数据。该数值包含一次 HTTP 请求往返和上传，不含推理，也不代表未来生产服务 API 的网络 SLA。

请求内容	上传大小 P50	请求往返 P50/P95	本机 JPEG 编码 P50/P95
1 KiB 探测	1 KiB	10.9/20.3 ms	—
两路未压缩 640×480 RGB	1800 KiB	109.9/204.8 ms	—
两路 JPEG quality=90	67 KiB	15.6/27.8 ms	3.6/3.8 ms

把传输探测与 4090 的 4/4/16 RGB 完整处理相加，未压缩输入的粗略 P50/P95 约 **454/556 ms**；JPEG quality=90 加上本机编码后约 **364/383 ms**。这是把两组独立测量相加的粗略估算，尚未含远端 JPEG 解码、真实服务响应体、机器人接口及网络高峰排队；应把 GB10 的本地推理作为稳定性基准。

复现

本机目录 `/home/airpiggy/Documents/ChatGPT/推理/fastwm-benchmark`；使用其 `.venv/bin/python`。入口：`code/scripts/cosmos/evaluate_joint8_experts.py`（`--stage sweep/events`）、`evaluate_joint8_video_quality.py`、`benchmark_joint8_experts.py`、`render_joint8_expert_demos.py`。命令完整保存在结果 `report.json` 和 `remote/run_benchmark.sh`；输入身份在 `assets/prepared-observations.identity.json`。不要在真实机械臂上直接复用本离线脚本。